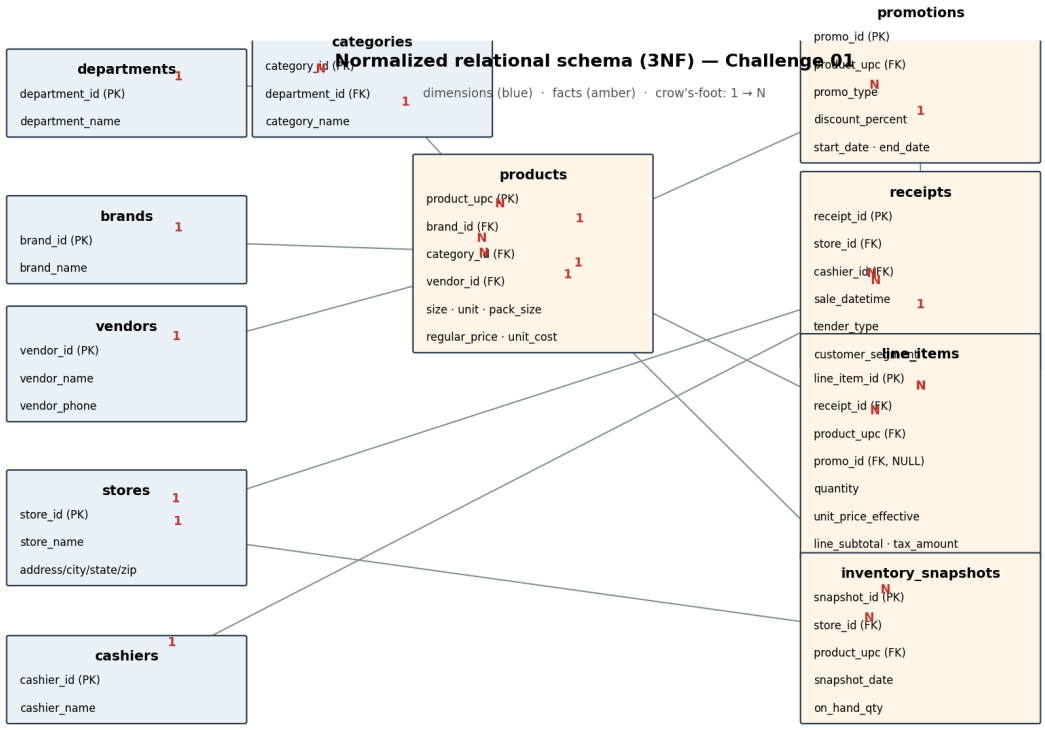
# 挑战 01 · 执行摘要

从数据混乱到分析清晰 —— 规范化关系型数据底座

## 2 流水线概览

四个平面文件（products / promotions / inventory / sales×4）经一条 ETL 命令重建为 11 张规范化表：7 维（departments · categories · brands · vendors · stores · cashiers · products）+ 4 事实（promotions · receipts · line_items · inventory_snapshots）。行数对账：products=60、promotions=530、stores=3、receipts=13,259、line_items=53,286、inventory=2,160，0 异常行。

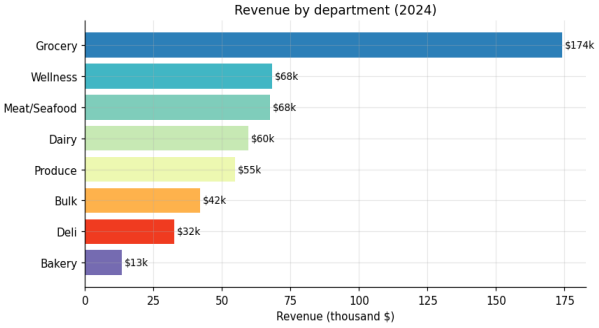
## 3 ERD 与模式设计

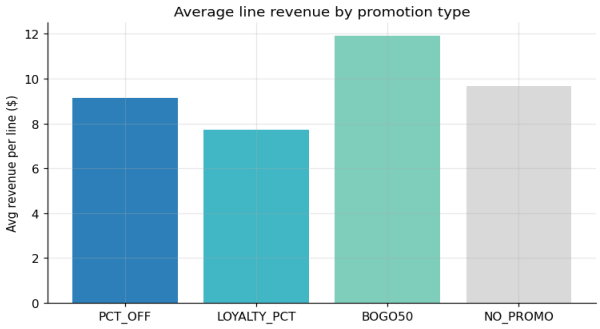



规范化 ERD（蓝=维度，琥珀=事实）

## 4 EDA 亮点

品类结构：Grocery 绝对主力（≈$174k，占 34%）；三店体量均衡、会员贡献更高。促销：BOGO50 把行均数量从 1.29 拉到 2.16、行均营收最高（提量型）。客群：会员 ≈59% 营收。

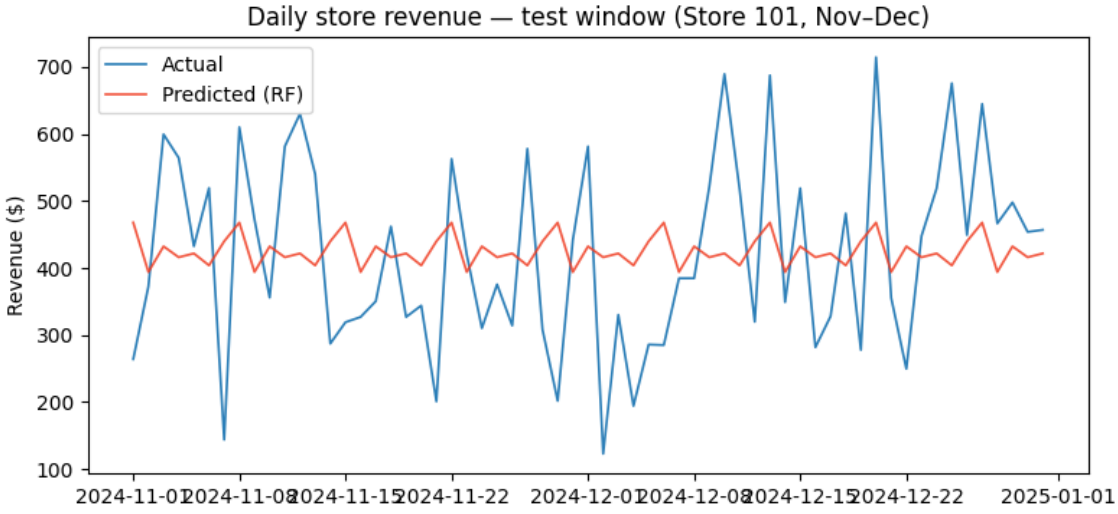





## 5 基线模型结果（单店每日销售预测）

时间切分：训练 1–10 月，测试 11–12 月（183 门店-日，覆盖 100%）。

| 模型 | MAE ($) | RMSE ($) | MAPE (%) |
|---|---|---|---|
| persistence（昨日值） | 176.1 | 224.1 | 41.42 |
| weekday_naive | 197.6 | 241.4 | 48.52 |
| random_forest | 135.8 | 170.6 | 33.05 |




测试窗口（Store 101）实际 vs 预测；RF 比最优朴素基线提升 15.5 个百分点

## 6 要点与下一步

· 可复现：一条命令从 7 文件重建库，行数严格一致、0 异常；· 可追踪：逐表计数日志 + 异常行落盘 rejected_rows.csv；· 就绪：EDA 与模型均由规范 schema 的标准 SQL 驱动。挑战 02 衔接：ETL 已预留「不可解析日期 / 外键孤儿 / 数值越界 / 重复键」拒绝路径。