1 概览

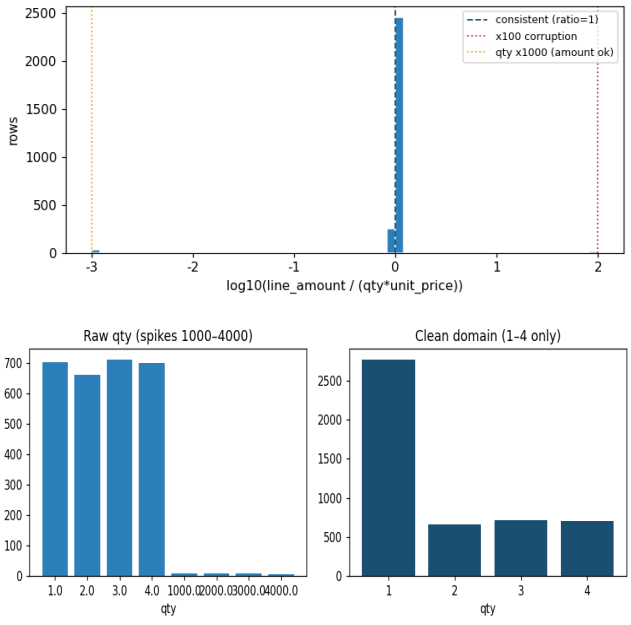
对一套结构化但充满噪音的杂货零售数据库做系统审计，共发现 9 类注入错误。修复遵循「精确还原优先」原则，其中 4 项（qty / unit_price / txn_date / store_id）从业务不变量精确反推，仅 product_id 因无信号而做种子化比例抽样。清洗后 18/18 项完整性校验通过，sales 从 2,859 行收敛到 2,809 行，总营收从 $265,880 修正为 $183,483（ 31.0%，移除 +44.9% 虚高）。

2 审计发现（9 类错误）

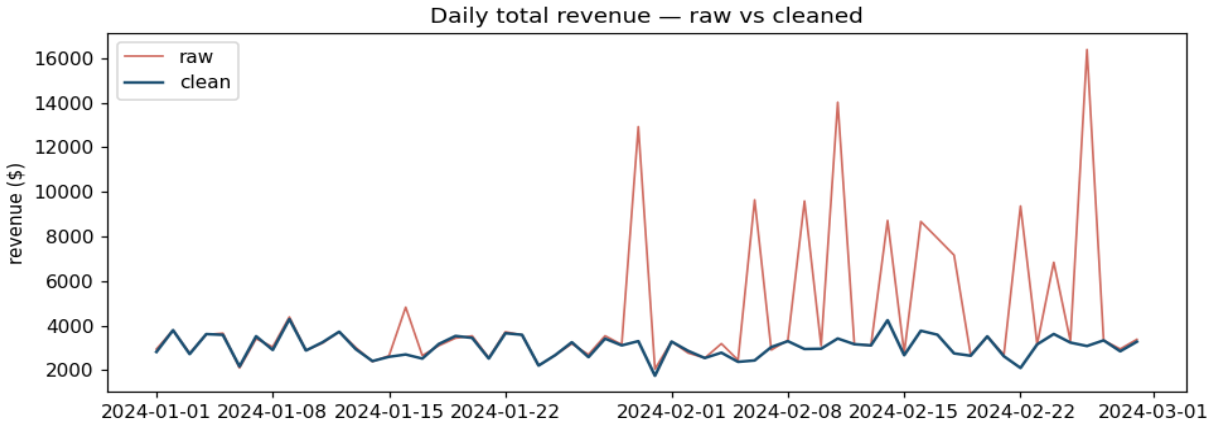
#	类别	表 · 列	计数
1	缺失 txn_date	sales.txn_date	29
2	缺失 qty	sales.qty	57
3	缺失 unit_price	sales.unit_price	56
4	重复 txn_id（47 同/3 冲突）	sales.txn_id	50 组
5	外键孤儿 store_id=9999	sales.store_id	14
6	外键孤儿 product_id=9999	sales.product_id	29
7	数量离群 1000–4000	sales.qty	29
8	金额不一致 ≠ qty×price	sales.line_amount	43
9	类别命名漂移	categories.name	2

3 修复策略：精确还原优先

精确还原：缺失 qty / unit_price 由派生不变量 line_amount = qty × unit_price 反推；缺失 txn_date 由 txn_id → 日期 的单调阶跃结构前向填充；store_id=9999 由每日门店 1→5 连续循环还原。数量离群 ÷1000、金额 ×100 重算。唯一无信号列 product_id 与任何观测列均不相关，采用种子化比例抽样保持边际分布无偏。



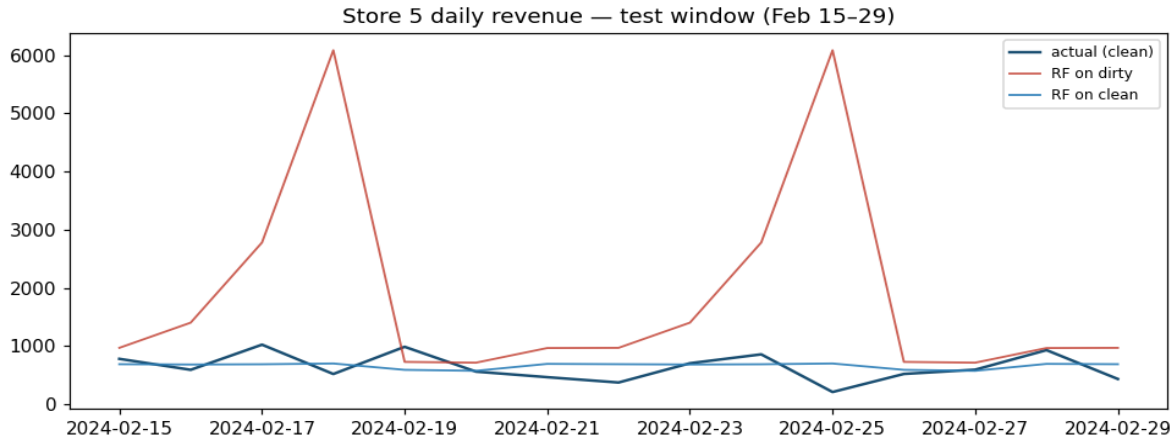
4 前后对比与验证



每日营收：清洗把虚高 43.6% 的曲线拉回真实水位，且不扭曲任何一日的形状

5 基线重测：脏数据 vs 清洗后

模型	MAPE（脏）	MAPE（清洗）	下降（×）
persistence	252.50%	79.95%	3.2×
weekday_naive	227.12%	57.29%	4.0×
random_forest	303.71%	65.32%	4.7×



测试窗口（门店 5）：脏数据训练的模型被 ×100 尖峰与重复计费带偏，清洗后误差回落到真实业务噪声地板

6 结论与下一步

· 可审计：9 类错误全量枚举，每步修复记录在 audit_log.csv 与 change_log.md；· 可复现：唯一随机源（product_id 抽样）固定种子 42，一条命令重放全链路；· 可信：18/18 校验通过、基线误差降低 3–5 倍，证明清洗消除失真而非制造跳跃。挑战 03 衔接：这份可信数据将作为时间序列预测（数据→信号）的建模地基。